RESEARCH BRIEF

迭代合成数学数据中的验证器可靠性

跨轮漂移 · 前缀敏感性 · 修复探索

从固定V的迭代实验出发，追踪表述变化怎样影响判断，
再检验修复旧错误与保留原有能力的取舍。

2026.10.20—10.27 | 七天流程与后续补充 | 导师交流材料

已完成一条“观察—诊断—修复”的研究链

跨轮可靠性

−3.24 pp

T299：G0→G2
固定V0的BA下降
95% CI [−6.06,−0.39]

表述敏感性

+10.55 pp

C95/G3：we can
提高FPR，同时降低FNR
数学正文与答案不变

修复与代价

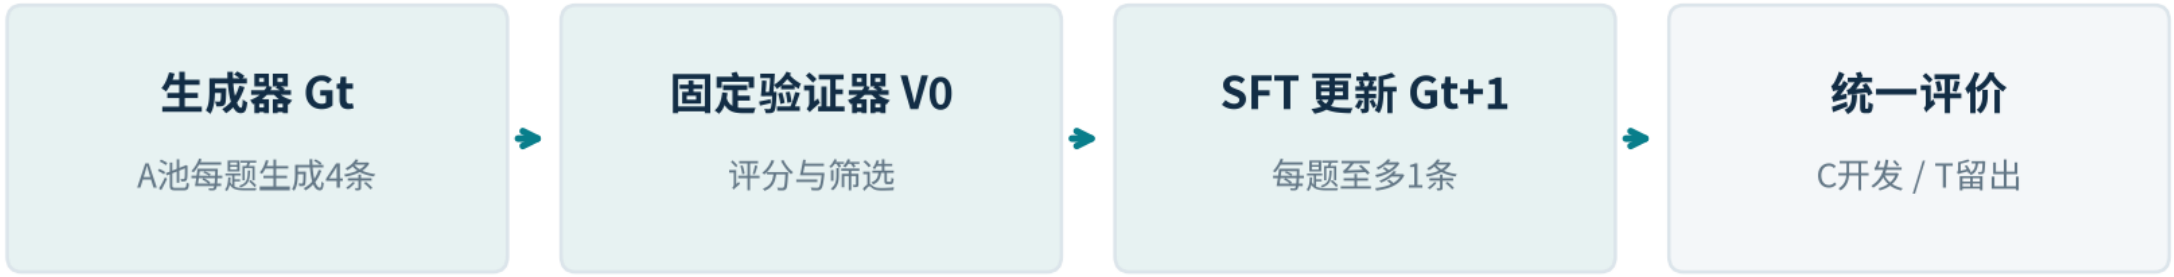
+5 条

E60/G3/we can：
DPO两组均净修复5条
同时新增7或8个FN

研究焦点：既看是否修好了错误，也看是否破坏了原本正确的判断。

固定V不变，回答分布会随G更新而变化

三个问题：跨轮是否稳定？表述是否影响判断？更新V怎样衡量得失？



G0是原始模型；G1/G2/G3依次更新1/2/3次。
A/B/C/T是题池；每个G阶段可以在多个题池上生成与评价。

主线固定V0更新G；修复实验另从V0开分支，保留原始轨迹与缓存。

原七天核心流程完成，后续围绕现象补对照

阶段	主题	完成内容
Day 1	环境与初测	模型部署、镜像测速、生成/评分/训练冒烟检查
Day 2	解析与任务诊断	GSM8K / MATH自然错误覆盖比较
Day 3	冻结DAPO协议	坏题、长度、标签、题池与工作点
Day 4—5	固定V0更新G	G0→G1→G2；G3为后续扩展
配套对照	监督质量与缓存	Vmatched / Oracle / Random、逐题监督权重
Day 6	更新V的原对照	Vrand / Vtarget，记录接受偏移与负结果
Day 7	T留出评价	T299统一引擎、混淆矩阵、区间与案例
后续补充	前缀诊断与修复	内容保持干预、机制对照、SFT × DPO

用有独立答案标签的数学任务研究V

G：Qwen2.5-Math-1.5B-Instruct ｜ V0：Qwen3-4B-Instruct-2507

池	主分析题数	用途	说明
A	600	G反馈训练题池	生成4候选，V0筛选后每题至多1条更新G
B	200	V训练题池	G监督选样不使用B回答；新修复训练取其中64题
C	95	开发与前缀诊断	初排4题后96，后续再隔离1道参考疑问题，主分析95
T	299	七天流程最终留出	所有G/V整题排除1道缺图题；每G1196回答
E	60	新V修复评价	所有G/V/前缀整题隔离4题；每G240回答

FPR：错误回答中被接受的比例　　FNR：正确回答中被拒绝的比例
BA = 1−(FPR+FNR)/2；每题4候选，未知单列，完整回答输入V。

G更新使用了怎样的监督?

A池4候选 → V0接受 → 每题至多随机1条 → 最多512条 / 1 epoch

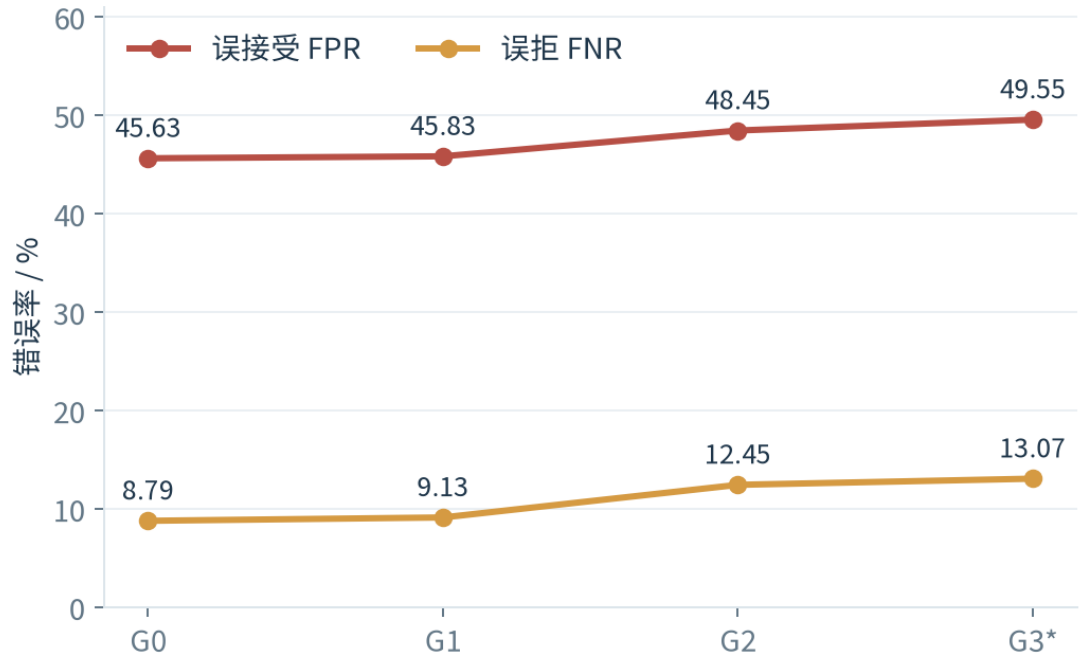
模型	样本	正确/错误/未知	有标签错误率	回答监督token	步数
G1	500	223/259/18	53.73%	414,830	63
G2	501	229/259/13	53.07%	419,895	63
G3	511	226/266/19	54.07%	414,590	64

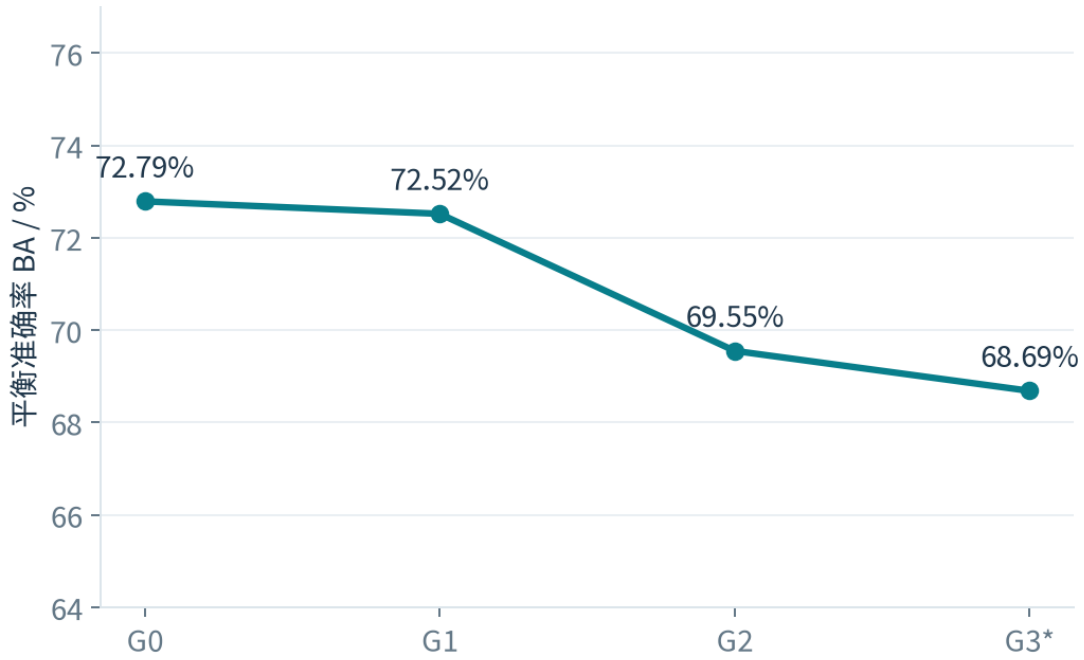
独立标签在选样后记录质量；主路线不按标准答案过滤。

训练数据含较多错误：这是含噪验证反馈下的更新，G正确率需独立评价。

T留出集上，固定V0的可靠性下降

T299 × 每题4回答；四个G统一vLLM评价；G3为扩展





G正确率约40%；G0→G2：BA −3.24pp，95% CI [−6.06,−0.39]。
FNR +3.65pp；FPR +2.82pp，后者区间跨0。

来源：week_final_20261026｜T299｜按题配对bootstrap 10,000次

更可靠的监督，还未转化成明确的G优势

同G0初始化、共同289道A题、37步；监督预算约22.5万回答token

分支	入训正确/错误/未知	G正确率	V0 FPR	V0 FNR
G0	—	42.54%	54.81%	14.94%
Random	198/80/11	40.56%	43.93%	12.33%
Vmatched	223/63/3	38.74%	52.91%	17.02%
Oracle	289/0/0	40.17%	53.99%	13.99%

C95上，三组未检出明确的G正确率优势；Random输出的FPR更低。
缓存审计提示：错误可识别性与逐题监督权重值得进一步分析。

从“什么变化了”转向可控的文本干预

由自然输出中的误判出发，检验常见表达能否改变验证器决定。

原始输入

同一题目
完整数学解答
最终答案

干预输入

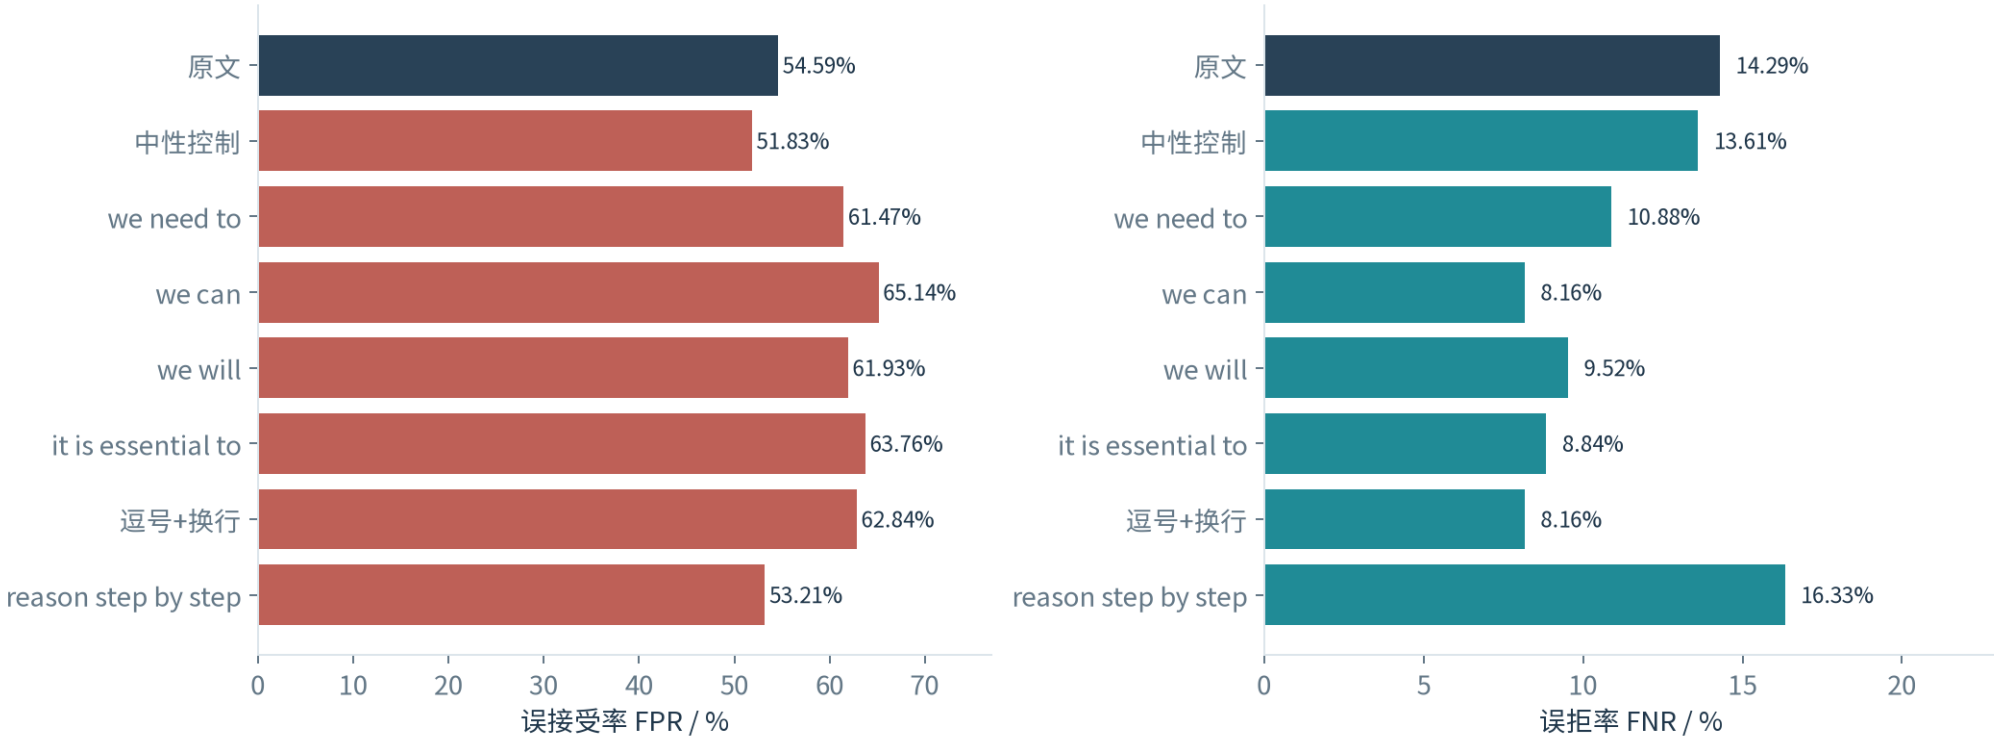
同一题目
we can + 原完整解答
相同最终答案

先确认原TN能否翻转，再补齐全部错误与正确回答，
同时记录两方向决定变化与连续分数。

数学正文与独立正确性标签保持不变，变化来自指定的表述干预。

部分前缀使V更愿接受：FPR升、FNR降

C95/G3：380回答 = 正确147 + 错误218 + 未知15；8设置，3,040逻辑评分



we can：23个TN→FP；10个FN→TP、1个TP→FN。影响同时涉及两类回答。

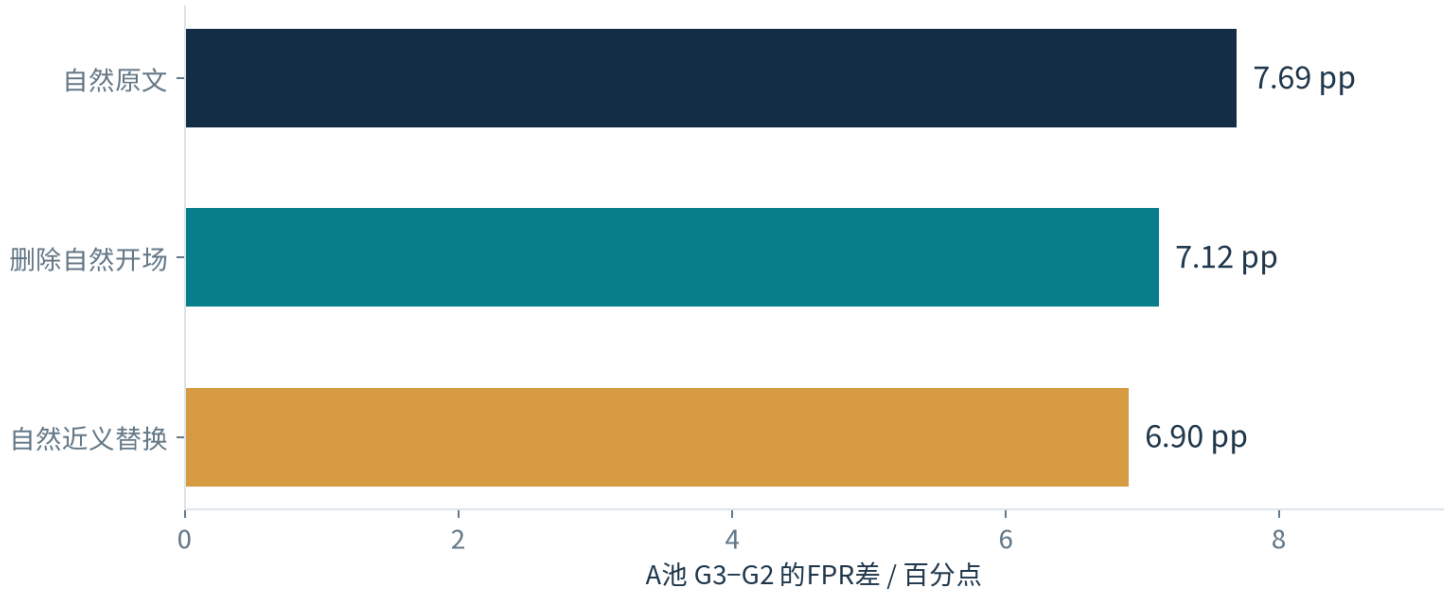
来源：prefix_full_panel_20261026｜固定V0、提示、A/B评分与0.5阈值

用系列对照逐步收束解释

问题	做了什么	得到什么
词汇学术性	20对AWL内外词	未显示AWL优势
前缀长度	字符、词数、token	纯长度不足以概括效果
输入题型	题型/符号条件FPR	未定位独有退化题型
训练链表达	候选→接受→SFT→输出	未见一致富集
自然删除/替换	同引擎G2/G3对称编辑	主要跨轮差距仍保留
四阶段同前缀	同题G0—G3、21设置	未见一致单调上涨

局部漏洞，与自然跨轮差距分别验证

A598，同vLLM引擎的G2/G3；改掉自然开场后重新评分



主要差距仍保留

原差距 7.69pp
删除后 7.12pp
替换后 6.90pp

继续研究更广的回答与错误组成。

可触发的局部误判已确认；自然漂移还需要更广的机制解释。

本人的研究切入与项目贡献

本人提出并推进

从跨轮误判提出表达敏感性假设
设计近义、AWL、长度、自然编辑对照
同时跟踪FP、FN与新增错误
将局部干预联系到真实SFT轨迹

借鉴并清楚引用

评审偏差：MT-Bench、BITE
短字符串与监督加固：AdvJudge-Zero
偏好优化目标：标准DPO
工程、缓存与图表：工具辅助

贡献定位：具体问题与对照设计、完整回答数据，以及跨轮和修复损伤的分析。

从V0独立开始：SFT × DPO × 前缀增强

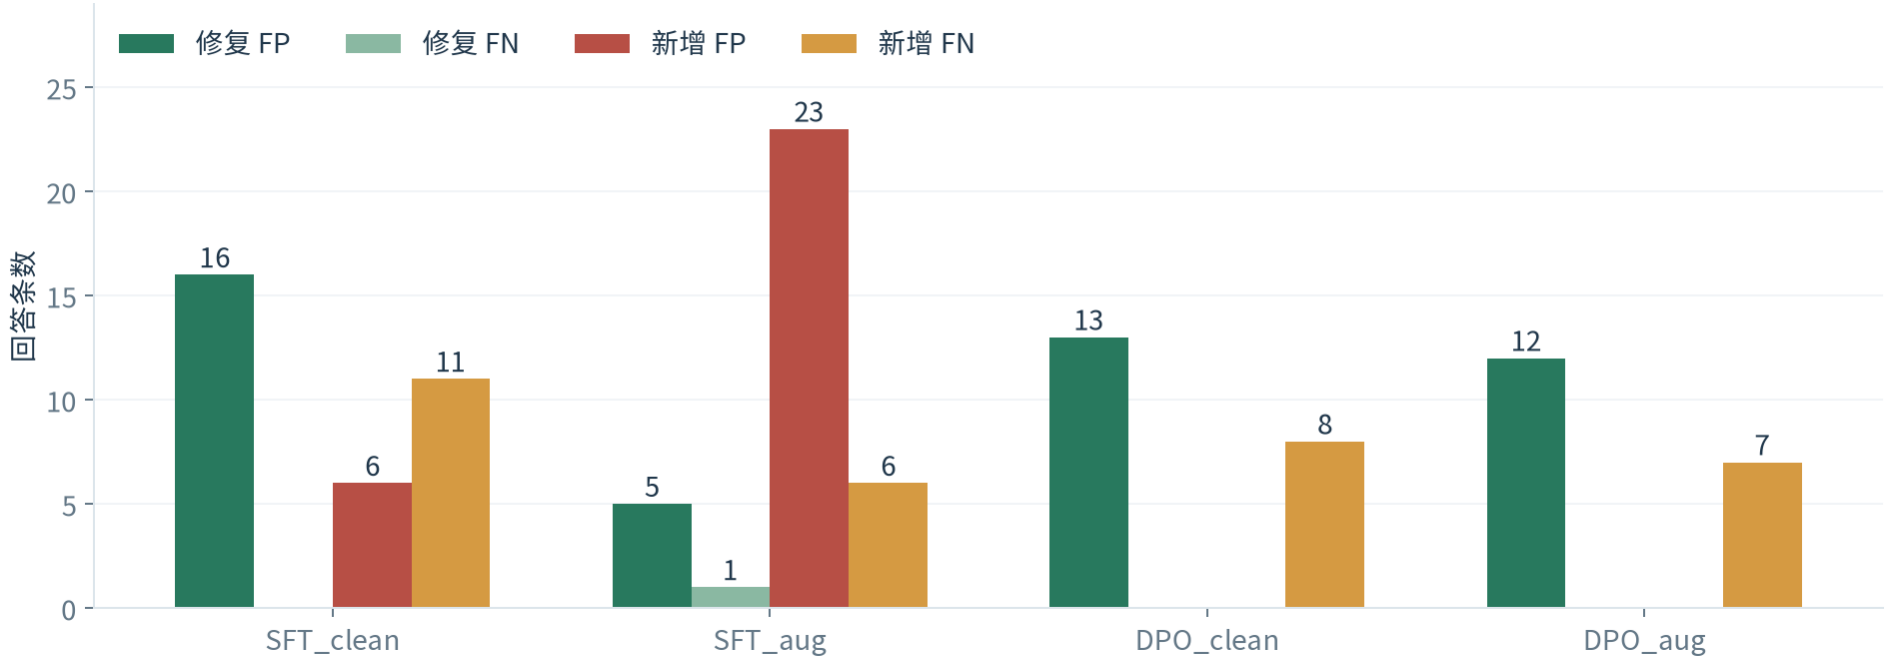
B/G0：64题、128完整回答、正负各64；每组640次呈现、80步

分支	输入构造	只学习判断标签
SFT_clean	原文 × 5	正确A/B的交叉熵
SFT_aug	原文 + 4前缀	同前缀覆盖正确与错误
DPO_clean	原文 × 5	正确标签chosen，错误标签rejected
DPO_aug	原文 + 4前缀	同上，参考模型为冻结V0

原Vrand/Vtarget曾出现过强接受倾向；本轮仅监督1个A/B token。
LoRA r8 / alpha16，LR 2e−5；不训练G正文，0.5阈值保持。

DPO修复部分FP，也新增FN

E60/G3/we can：240回答，已知220、未知20；均相对同一输入上的V0



净修复：SFT_clean −1；SFT_aug −23；DPO两组均 +5。
DPO_aug：FPR 34.11%→24.81%，FNR 8.79%→16.48%。

来源：verifier_robustness_clean_20261026｜四组从V0独立初始化，原数据和模型保留

局部修好，与整体净改善是两个层次

局部修复

7 / 7

两组DPO都修复V0因we can注入新增的7个FP，且两版本均判对。

新的问题

7 / 3

对各自原文再注入，DPO_clean / aug仍分别新增7 / 3个FP。

增强的净增益

0 条

DPO_aug−clean主比较净差0；95%区间为[−1.82,+1.81]pp。

当前DPO收益主要体现为更保守的判断；下一步需保留正确接受、提高净收益。

目前已形成什么研究判断?

01

固定V面对更新后的G输出，可靠性确实需要重新检验。

T上BA下降；G正确率未明显提高。

02

一些常见前缀能够改变验证器决定。

完整面板同时量化误接受增加和误拒减少。

03

简单删除或小规模增强训练都存在取舍。

应以修复FP/FN与新增FP/FN共同评价。

下一步：让判定稳定，同时保持内容区分

工作点与判别能力分开

比较风险—保留率曲线和相同FNR/保留率；检查是否只是更保守。

提高修复数据覆盖

增加正确接受保持样本；按表达家族留出，跟踪新增FN来源。

复现后进入新一轮反馈

少量种子与人工数学核验；冻结配置后新题确认，再将修复V放回G循环。

现有基础：可追溯的G/V模型、完整回答、独立标签、连续分数、题池和训练记录。

数据口径与代表性文献

最终答案标签；未知单列；坏题整题隔离；区间按题配对。
C用于开发，T299为七天留出，E60为新修复题池；结果分别呈现。
单条G训练轨迹、单种子修复；后续先复现，再扩大。

[R1] Zheng et al. (2023) · Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

https://arxiv.org/abs/2306.05685

[R2] AdvJudge-Zero v3 · Binary Decision Flips in LLM-as-a-Judge via Adversarial Control Tokens

https://arxiv.org/html/2512.17375v3

[R3] Yang et al. (2026) · Turning Bias into Bugs: Bandit-Guided Style Manipulation Attacks on LLM Judges

https://arxiv.org/abs/2605.26156

[R4] Rafailov et al. (2023) · Direct Preference Optimization: Your Language Model is Secretly a Reward Model

https://arxiv.org/abs/2305.18290